Introducción a la ciencia de datos

Nuevas tecnologías, salud digital y farmacia

Introducción a la ciencia de datos

Juan Pajaro

Phd (c) en ingeniería

Modelos de IA aplicados a la investigación en salud

Agenda

- Inteligencia artificial, Aprendizaje automático y Ciencia de datos
- ¿Qué es un algoritmo? ¿Qué es un modelo?
- ¿Qué es la ciencia de datos?
- Caso de uso
- Método
- Taller

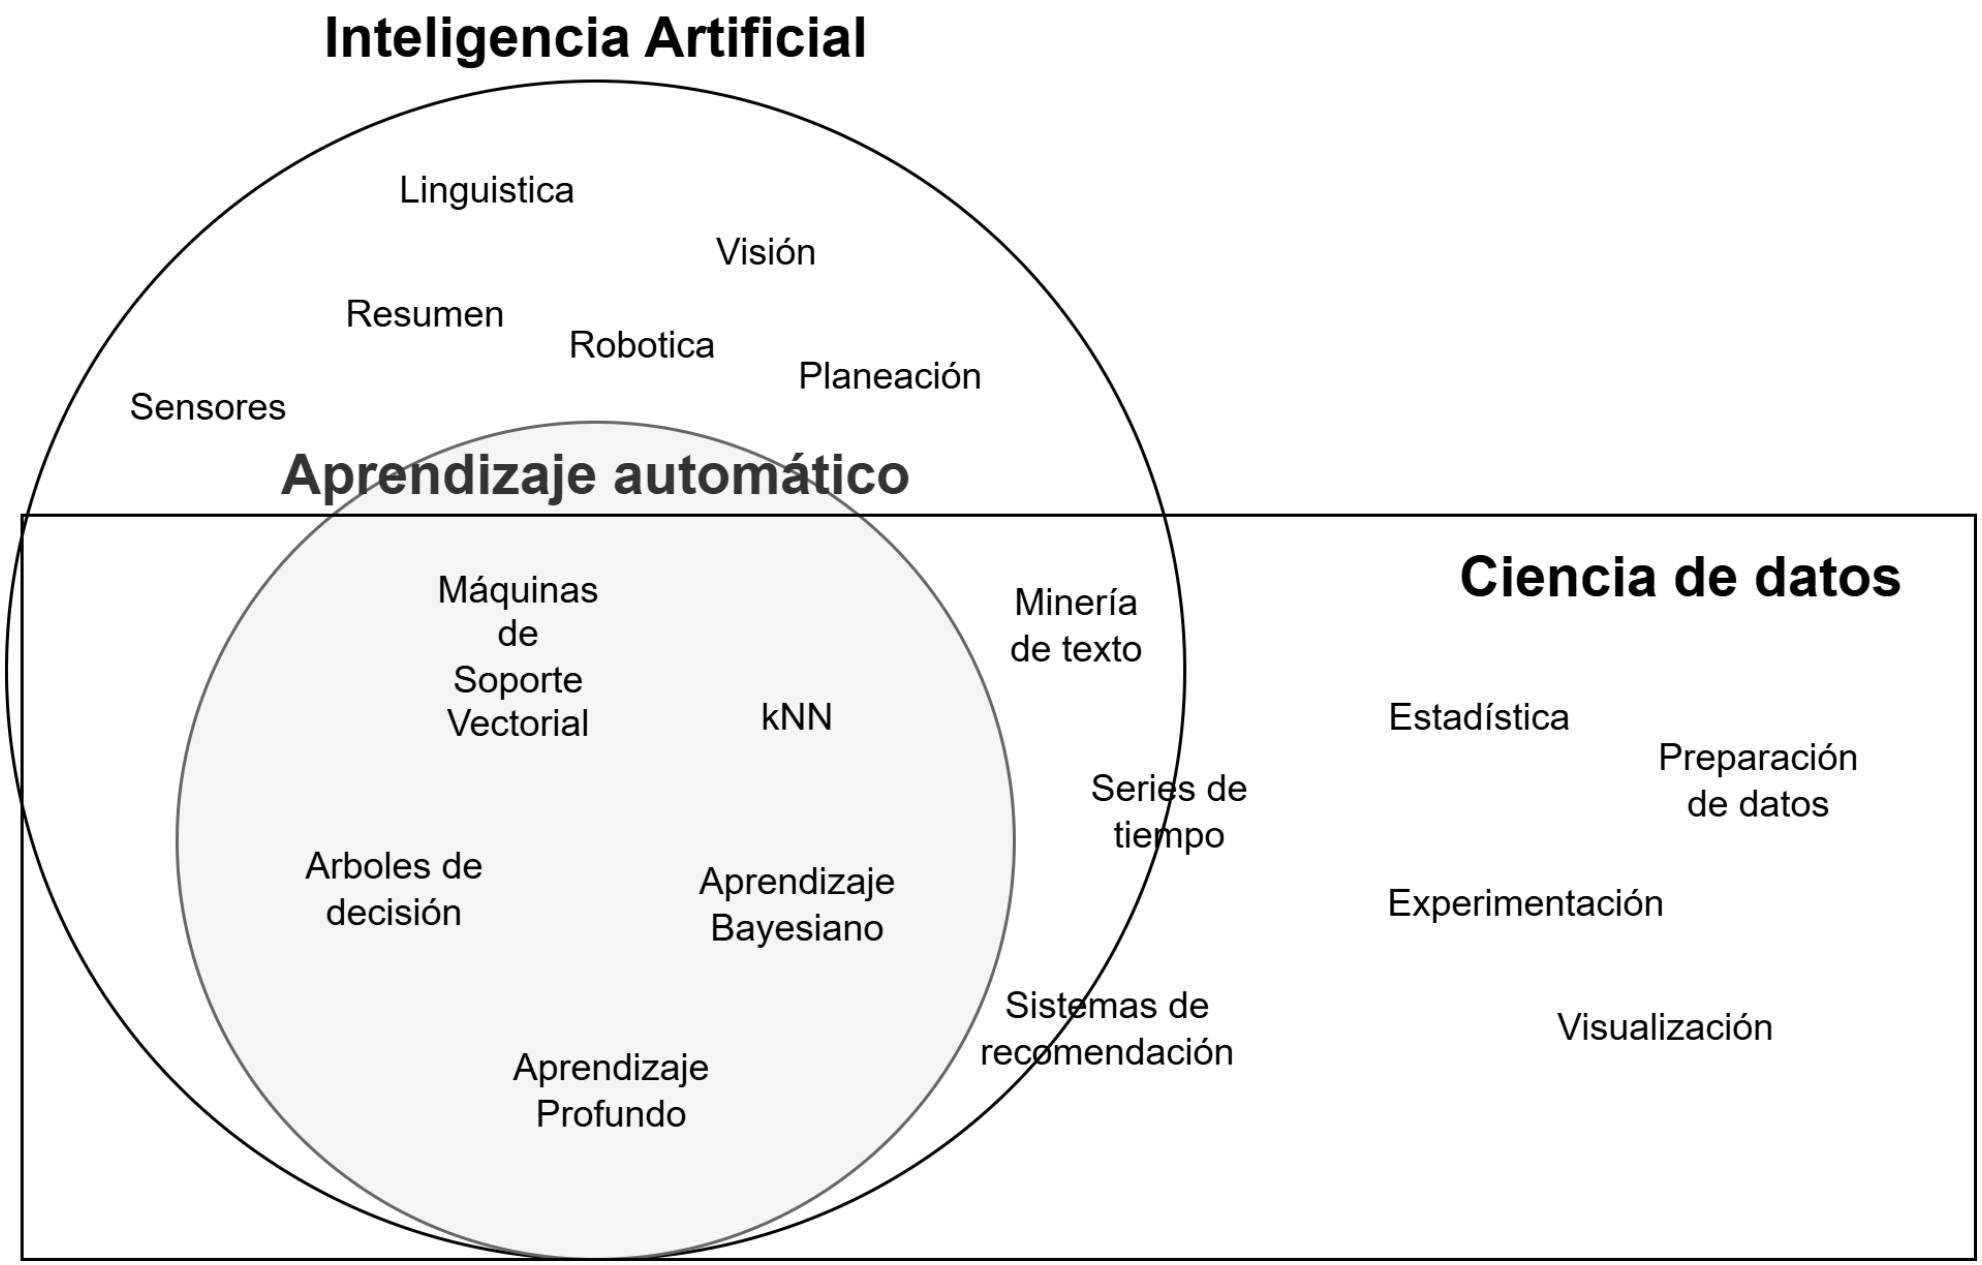
Inteligencia Artificial
Linguistica
Visión
Resumen
Robotica
Planeación
Sensores
Aprendizaje automático
Máquinas de Soporte Vectorial
kNN
Arboles de decisión
Aprendizaje Bayesiano
Aprendizaje Profundo
Minería de texto
Series de tiempo
Sistemas de recomendación
Ciencia de datos
Estadística
Preparación de datos
Experimentación
Visualización

Programación tradicional y aprendizaje de automático

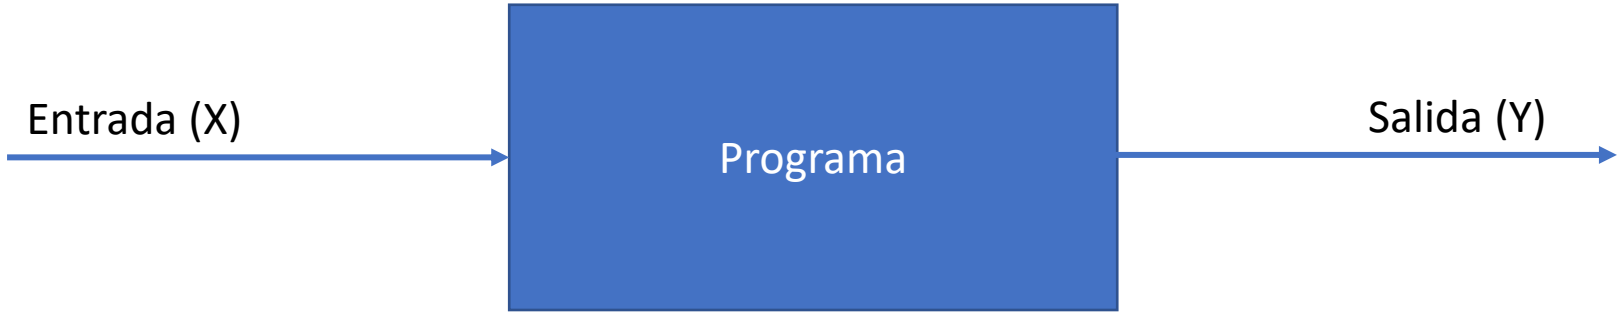

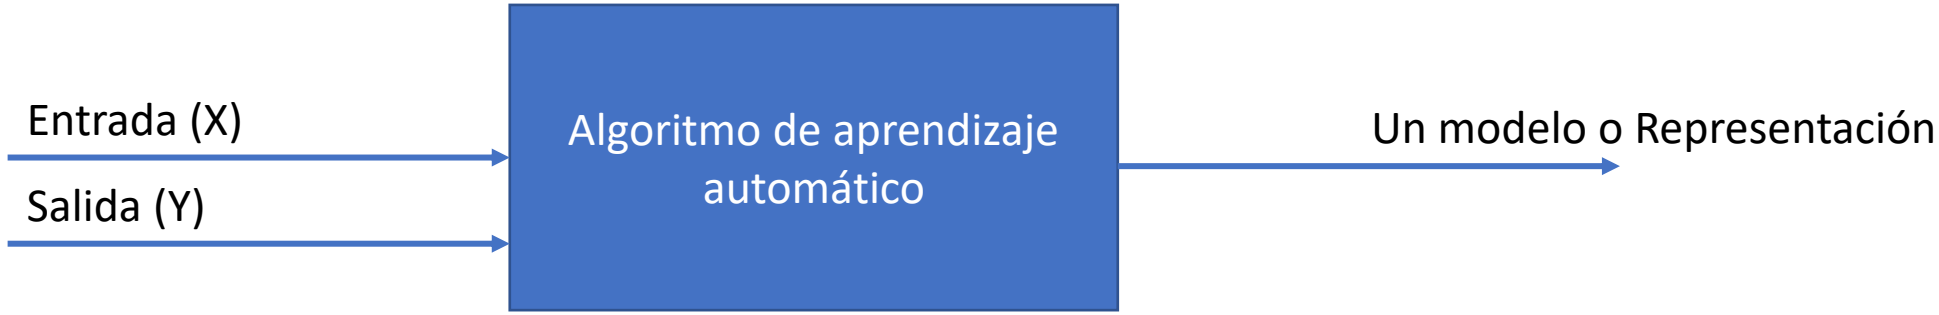

¿Qué es un algoritmo? ¿Qué es un modelo?

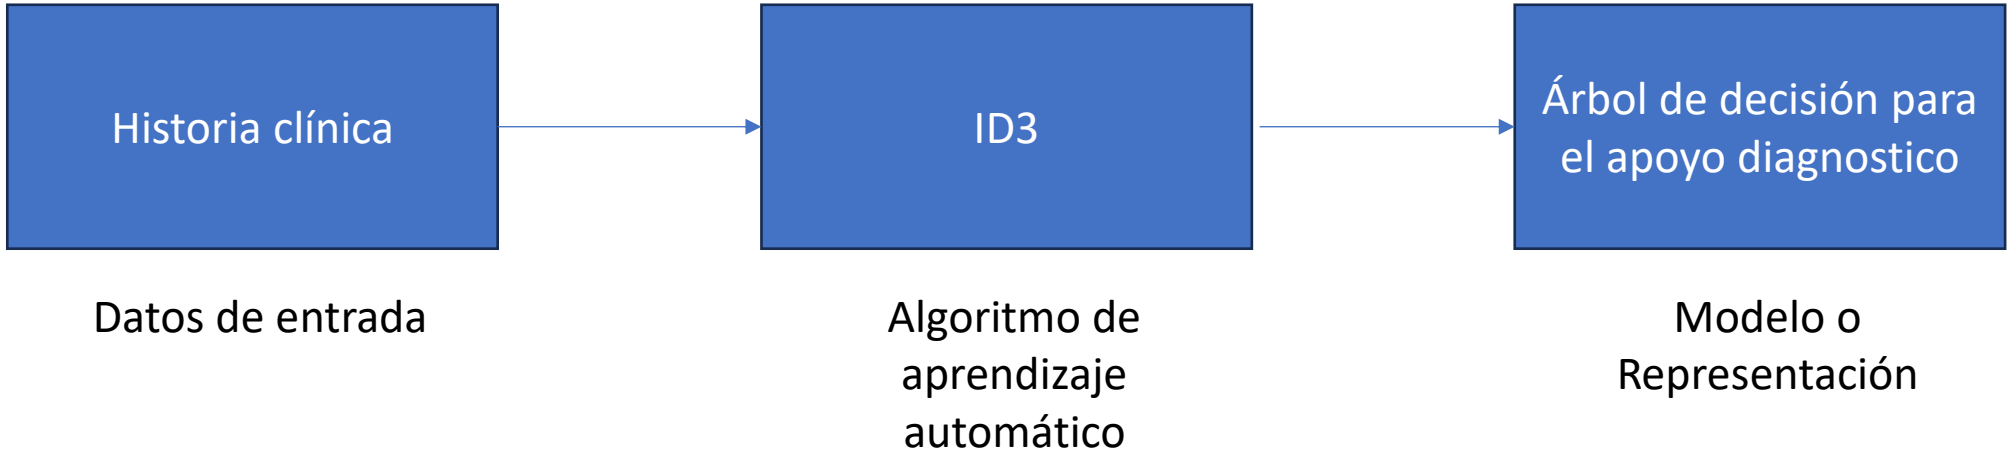

¿Qué es un algoritmo? ¿Qué es un modelo?

- Un algoritmo informático es un conjunto generalizado de instrucciones de computadora (independiente del lenguaje de programación) diseñado para resolver una clase de problemas.
- Un modelo de aprendizaje automático es una representación computacional de algún dominio (problema-solución), el cual al recibir un conjunto de datos de entrada (instancias del problema), obtiene una solución a estos.

Ejemplo de tablero

- Modelo de riesgo cardiovascular simple.
- Edad, Colesterol, Tabaquismo y Ejercicio.
- Algoritmo: regresión lineal (función matemática, función de perdida, algoritmo de optimización).
- Modelo: $$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p.$$

¿Qué es la ciencia de datos?

- Extracción de patrones significativos.
- Construcción de modelos representativos.
- Combinación de estadística, aprendizaje automático y computación.

Caso de uso

- Volumen (retinopatía diabética, 11 oftalmólogos por millón de personas).
- Dimensiones (ejemplo embedding projector).
- Preguntas complejas (¿Cuál es la estructura de las proteínas? Premio nobel de química 2024)

Volumen (Retinopatía diabética)

- Retinopatía diabética – factor de riesgo para la ceguera.
- 11 oftalmólogos por millón de hab. (India)

Conjunto de datos

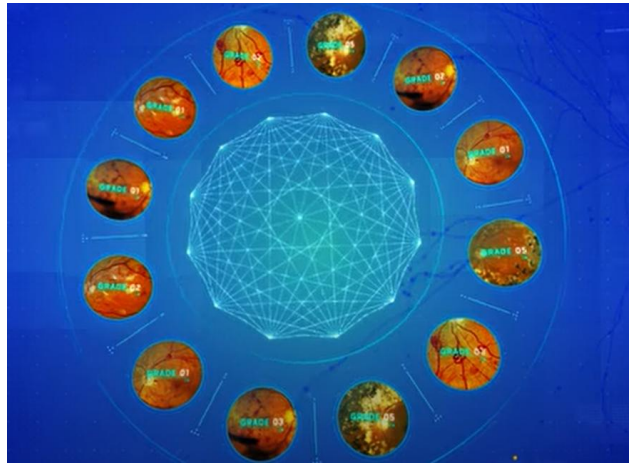

Entrenamiento

Despliegue

Práctica clínica

Dimensiones (ejemplo embedding projector)

- https://projector.tensorflow.org/

Preguntas complejas (¿Cuál es la estructura de las proteínas? Premio nobel de química 2024)

- Desde la década de 1970, los investigadores habían intentado predecir la estructura de las proteínas a partir de secuencias de aminoácidos, pero esto era notoriamente difícil.
- En 2003, David Baker logró utilizar las estructuras de las proteínas para diseñar una proteína nueva que no se parecía a ninguna existente.
- Su grupo de investigación ha producido una proteína nueva tras otra, incluidas proteínas que pueden usarse como fármacos, vacunas, nanomateriales y sensores diminutos.

Preguntas complejas (¿Cuál es la estructura de las proteínas? Premio nobel de química 2024)

- En 2020, Demis Hassabis y John Jumper presentaron un modelo de inteligencia artificial llamado AlphaFold2.
- Con éste, han podido predecir la estructura de prácticamente la totalidad de los 200 millones de proteínas que los investigadores han identificado.

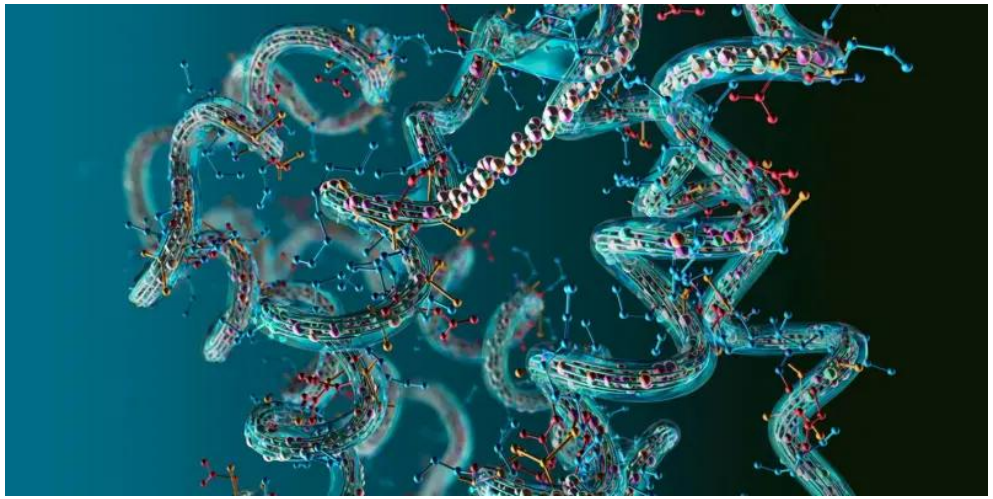

Método

Gestión de datos

- Recolección
- Análisis exploratorio de datos (EDA)
- Preparación de datos (entrenamiento-prueba)

Entrenamiento de algoritmos

- Selección del algoritmo
- Ajuste de hiperparametros
- Entrenamiento

Evaluación del modelo

- Selección de una métrica de evaluación
- Evaluación del desempeño usando prueba

Método

Gestión de datos

- Análisis exploratorio de datos (EDA)
- Preparación de datos (entrenamiento-prueba)

Entrenamiento de algoritmos

- Vamos a seleccionar dos algoritmos (árbol de decisión y regresión logística)

Evaluación del modelo

- Todo por encima de una exactitud del 82% es un buen modelo.